# 回帰分析

### 回帰モデルの考え方と推定

村田 昇

## 講義の内容

- **第 1 回：回帰モデルの考え方と推定**
- 第 2 回：モデルの評価
- 第 3 回：モデルによる予測と発展的なモデル

## 回帰分析の考え方

### 回帰分析

- ある変量を別の変量で説明する関係式を構成する
- 関係式：**回帰式** (regression equation)
  - 説明される側：**目的変数**, 被説明変数, 従属変数, 応答変数
  - 説明する側：**説明変数**, 独立変数, 共変量
- 説明変数の数による分類
  - 一つの場合：**単回帰** (simple regression)
  - 複数の場合：**重回帰** (multiple regression)

### 一般の回帰の枠組

- **説明変数**：$x_1, \ldots, x_p$ (p 次元)
- **目的変数**：$y$ (1 次元)
- **回帰式**：$y$ を $x_1, \ldots, x_p$ で説明するための関係式

$$y = f(x_1, \ldots, x_p)$$

- 観測データ：n 個の $(y, x_1, \dots, x_p)$ の組

$$\{(y_i, x_{i1}, \dots, x_{ip})\}_{i=1}^{n}$$

## 線形回帰

- 任意の $f$ では一般的すぎて分析に不向き
- $f$ として **1 次関数** を考える
  ある定数 $\beta_0, \beta_1, \dots, \beta_p$ を用いた式：

$$f(x_1, \dots, x_p) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

  - 1 次関数の場合：**線形回帰** (linear regression)
  - 一般の場合：非線形回帰 (nonlinear regression)

- 非線形関係は新たな説明変数の導入で対応可能
  - 適切な多項式：$x_j^2, x_j x_k, x_j x_k x_l, \dots$
  - その他の非線形変換：$\log x_j, x_j^\alpha, \dots$
  - 全ての非線形関係ではないことに注意

## 回帰係数

- 線形回帰式

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

  - $\beta_0, \beta_1, \dots, \beta_p$：**回帰係数** (regression coefficients)
  - $\beta_0$：**定数項 / 切片** (constant term / intercept)

- 線形回帰分析 (linear regression analysis)
  - 未知の回帰係数をデータから決定する分析方法
  - 決定された回帰係数の統計的な性質を診断

### 回帰の確率モデル

- 回帰式の不確定性
  - データは一般に観測誤差などランダムな変動を含む
  - 回帰式がそのまま成立することは期待できない
- 確率モデル：データのばらつきを表す項 $\epsilon_i$ を追加

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \epsilon_i \quad (i = 1, \ldots, n)$$

  - $\epsilon_1, \ldots, \epsilon_n$：**誤差項 / 撹乱項** (error / disturbance term)
    - 誤差項は独立な確率変数と仮定
    - 多くの場合，平均 0，分散 $\sigma^2$ の正規分布を仮定
- **推定** (estimation)：観測データから回帰係数を決定

## 回帰係数の推定

### 残差

- **残差** (residual)：回帰式で説明できない変動
- 回帰係数 $\beta = (\beta_0, \beta_1, \ldots, \beta_p)^\mathsf{T}$ を持つ回帰式の残差

$$e_i(\beta) = y_i - (\beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}) \quad (i = 1, \ldots, n)$$

- 残差 $e_i(\beta)$ の絶対値が小さいほど当てはまりがよい

### 最小二乗法

- **残差平方和** (residual sum of squares)

$$S(\beta) = \sum_{i=1}^{n} e_i(\beta)^2$$

- **最小二乗推定量** (least squares estimator)：$S(\beta)$ を最小にする $\beta$

$$\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_p)^\mathsf{T} = \arg\min_{\beta} S(\beta)$$

## 行列の定義

- デザイン行列 (design matrix)

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

  - $n \times (p{+}1)$ 行列

## ベクトルの定義

- 目的変数，誤差，回帰係数のベクトル

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

  - $y, \epsilon$ は $n$ 次元ベクトル
  - $\beta$ は $p{+}1$ 次元ベクトル

## 行列・ベクトルによる表現

- 確率モデル

$$y = X\beta + \epsilon$$

- 残差平方和

$$S(\beta) = (y - X\beta)^{\mathsf{T}}(y - X\beta)$$

## 解の条件

- 解 $\beta$ では残差平方和の勾配は零ベクトル

$$\nabla S(\beta) = \Big(\frac{\partial S}{\partial \beta_0}(\beta), \frac{\partial S}{\partial \beta_1}(\beta), \ldots, \frac{\partial S}{\partial \beta_p}(\beta)\Big)^{\mathsf{T}} = 0$$

- 成分 $(j = 0, 1, \dots, p)$ ごとの条件式

$$\frac{\partial S}{\partial \beta_j}(\beta) = -2 \sum_{i=1}^{n} \Big( y_i - \sum_{k=0}^{p} \beta_k x_{ik} \Big) x_{ij} = 0$$

  ただし $x_{i0} = 1$ $(i = 1, \dots, n)$

# 正規方程式

## 正規方程式

**正規方程式 (normal equation)**

$$X^{\mathsf{T}} X \beta = X^{\mathsf{T}} y$$

- $X^{\mathsf{T}} X$ : **Gram 行列** (Gram matrix)
  - $(p+1) \times (p+1)$ 行列 (正方行列)
  - 半正定値行列 (固有値が非負)

## 正規方程式の解

- 正規方程式の基本的な性質
  - 正規方程式の解は最小二乗推定量であるための必要十分条件
  - 正規方程式は必ず解をもつ (一意に決まらない場合もある)
- 解の一意性の条件
  - Gram 行列 $X^{\mathsf{T}} X$ が **正則** (逆行列をもつ)
  - $X$ の列ベクトルが独立 (後述)

**正規方程式の解**

$$\hat{\beta} = (X^{\mathsf{T}} X)^{-1} X^{\mathsf{T}} y$$

# 実習

# 最小二乗推定量の性質

## 解析の上での良い条件

- 最小二乗推定量がただ一つだけ存在する条件
  - $X^{\mathsf{T}}X$ が正則
  - $X^{\mathsf{T}}X$ の階数が $p$+1
  - $X$ の階数が $p$+1
  - $X$ の列ベクトルが **1 次独立**
- これらは同値条件

## 解析の上での良くない条件

- 説明変数が 1 次従属： **多重共線性** (multicollinearity)
- 多重共線性が強くならないように説明変数を選択
  - $X$ の列 (説明変数) の独立性を担保する
  - 説明変数が互いに異なる情報をもつように選ぶ
  - 似た性質をもつ説明変数の重複は避ける

## 推定の幾何学的解釈

- **あてはめ値** (fitted values)

$$\hat{y} = X\hat{\beta} = \hat{\beta}_0 X_{0(\text{切片})} + \cdots + \hat{\beta}_p X_{p(\text{第 p 成分})}$$

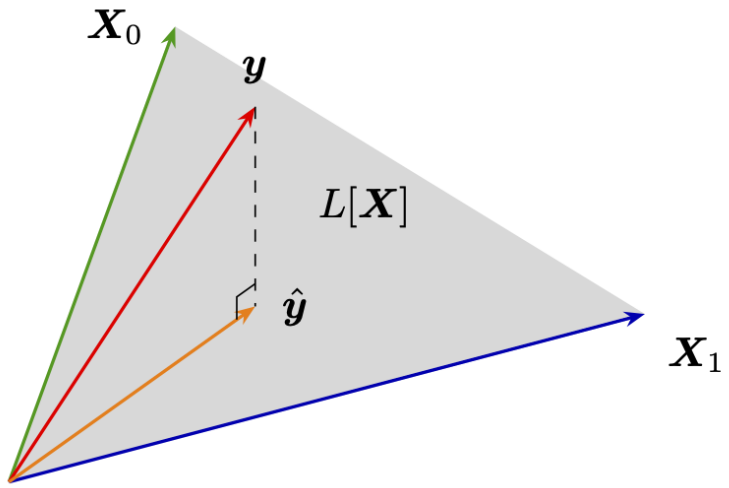



Figure 1: $n = 3$ , $p + 1 = 2$ の場合の最小二乗法による推定

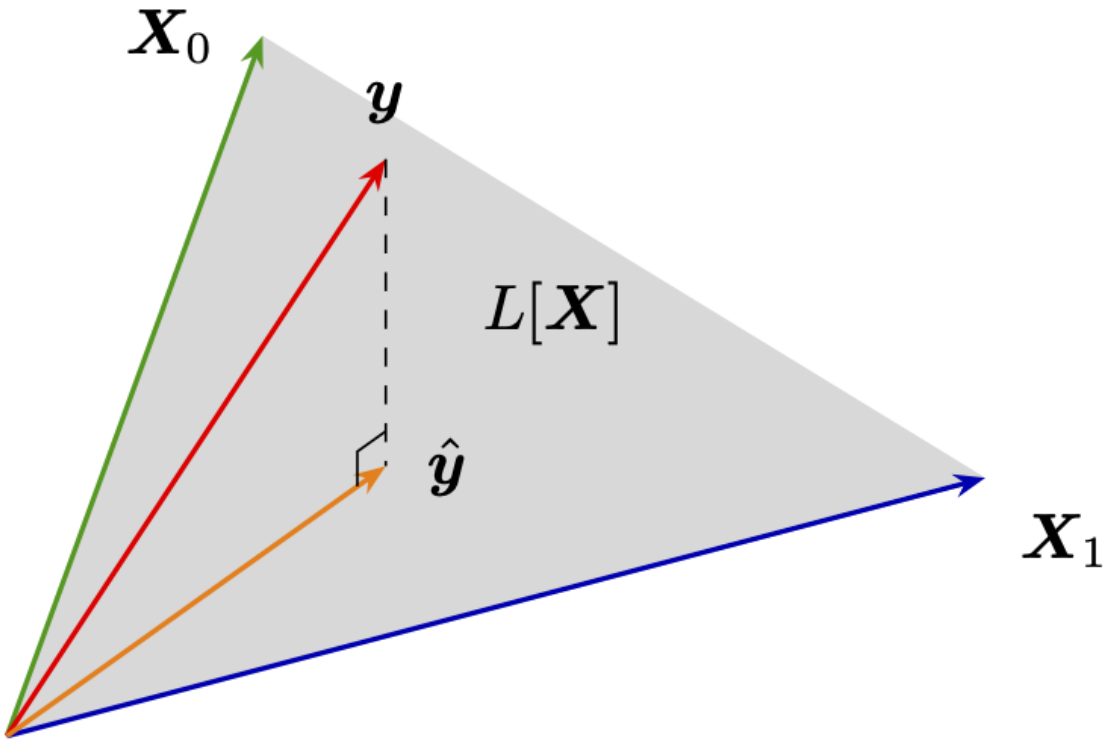



Figure 2: $n = 3$ , $p + 1 = 2$ の場合

- 最小二乗推定量 $\hat{y}$ の幾何学的性質
  - $L[X]$ : $X$ の列ベクトルが張る $\mathbb{R}^n$ の線形部分空間
  - $X$ の階数が $p$+1 ならば $L[X]$ の次元は $p$+1 (解の一意性)
  - $\hat{y}$ は $y$ の $L[X]$ への直交射影
  - **残差** (residuals) $\hat{\epsilon} = y - \hat{y}$ はあてはめ値 $\hat{y}$ に直交

$$\hat{\epsilon} \cdot \hat{y} = 0$$

### 線形回帰式と標本平均

- $x_i = (x_{i1}, \dots, x_{ip})^{\mathsf{T}}$: $i$ 番目の観測データの説明変数
- 説明変数および目的変数の標本平均

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i,$$

- $\hat{\beta}$ が最小二乗推定量のとき以下が成立

$$\bar{y} = (1, \bar{x}^{\mathsf{T}})\hat{\beta}$$

## 実習

## 残差の分解

### 最小二乗推定量の残差

- 観測値と推定値 $\hat{\beta}$ によるあてはめ値の差

$$\hat{\epsilon}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_p x_{ip}) \quad (i = 1, \dots, n)$$

  - 誤差項 $\epsilon_1, \dots, \epsilon_n$ の推定値
  - 全てができるだけ小さいほど良い
  - あてはめ値とは独立に偏りがないほど良い
- 残差ベクトル

$$\hat{\epsilon} = y - \hat{y} = (\hat{\epsilon}_1, \hat{\epsilon}_2, \dots, \hat{\epsilon}_n)^{\mathsf{T}}$$

### 平方和の分解

- $\bar{y} = \bar{y}1 = (\bar{y}, \bar{y}, \ldots, \bar{y})^{\mathsf{T}}$：標本平均のベクトル (データ数=$n$ 次元)
- いろいろなばらつき
  - $S_y = (y - \bar{y})^{\mathsf{T}}(y - \bar{y})$：目的変数のばらつき
  - $S \ = (y - \hat{y})^{\mathsf{T}}(y - \hat{y})$：残差のばらつき ($\hat{\epsilon}^{\mathsf{T}}\hat{\epsilon}$)
  - $S_r = (\hat{y} - \bar{y})^{\mathsf{T}}(\hat{y} - \bar{y})$：あてはめ値 (回帰) のばらつき
- 3 つのばらつき (平方和) の関係

$$(y - \bar{y})^{\mathsf{T}}(y - \bar{y}) = (y - \hat{y})^{\mathsf{T}}(y - \hat{y}) + (\hat{y} - \bar{y})^{\mathsf{T}}(\hat{y} - \bar{y})$$

$$S_y = S + S_r$$

## 実習

## 決定係数

### 回帰式の寄与

- ばらつきの分解

$$S_y \text{ (目的変数)} = S \text{ (残差)} + S_r \text{ (あてはめ値)}$$

- 回帰式で説明できるばらつきの比率

$$\text{(回帰式の寄与率)} = \frac{S_r}{S_y} = 1 - \frac{S}{S_y}$$

- 回帰式のあてはまり具合を評価する代表的な指標

### 決定係数 ($R^2$ 値)

**決定係数 (R-squared)**

$$R^2 = 1 - \frac{\sum_{i=1}^{n} \hat{\epsilon}_i^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2}$$

**自由度調整済み決定係数 (adjusted R-squared)**

$$\bar{R}^2 = 1 - \frac{\frac{1}{n-p-1}\sum_{i=1}^{n}\hat{\epsilon}_i^2}{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

- 不偏分散で補正している

## 実習

## 次回の予定

- 第 1 回：回帰モデルの考え方と推定
- **第 2 回：モデルの評価**
- 第 3 回：モデルによる予測と発展的なモデル