

回帰分析

モデルの評価

村田 昇

講義の内容

- 第1回：回帰モデルの考え方と推定
- 第2回：モデルの評価
- 第3回：モデルによる予測と発展的なモデル

回帰分析の復習

線形回帰モデル

- 目的変数 を 説明変数 で説明する関係式を構成
 - 説明変数： $x_1, \dots, x_p$ (p 次元)
 - 目的変数： y (1 次元)
- 回帰係数 $\beta_0, \beta_1, \dots, \beta_p$ を用いた一次式

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

- 誤差項 を含む確率モデルで観測データを表現

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \epsilon_i \quad (i = 1, \dots, n)$$

簡潔な表現のための行列

- デザイン行列 (説明変数)

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

簡潔な表現のためのベクトル

- ベクトル (目的変数・誤差・回帰係数)

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

問題の記述

- 確率モデル

$$y = X\beta + \epsilon, \quad \epsilon \sim \text{確率分布}$$

- 回帰式の推定：残差平方和 の最小化

$$S(\beta) = (y - X\beta)^\top (y - X\beta)$$

解の表現

- 解の条件：正規方程式

$$X^\top X\beta = X^\top y$$

- 解の一意性：Gram 行列 $X^\top X$ が正則

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

最小二乗推定量の性質

- あてはめ値 $\hat{y} = X\hat{\beta}$ は X の列ベクトルの線形結合
- 残差 $\hat{\epsilon} = y - \hat{y}$ はあてはめ値 $\hat{y}$ と直交

$$\hat{\epsilon}^T \hat{y} = 0$$

- 回帰式は説明変数と目的変数の **標本平均** を通過

$$\bar{y} = (1, \bar{x}^T) \hat{\beta}, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

寄与率

- 決定係数 (R-squared)

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- 自由度調整済み決定係数 (adjusted R-squared)

$$\bar{R}^2 = 1 - \frac{\frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

– 不偏分散で補正

解析の事例

実データによる例

- 気象庁より取得した東京の気候データ
 - 気象庁 <https://www.data.jma.go.jp/gmd/risk/obsdl/index.php>
- 気温に影響を与える要因を分析

Table 1: 東京の8月の気候データ

日付	気温	降雨	日射	降雪	風向	風速	気圧	湿度	雲量
2025-08-01	26.4	6.0	9.16	0	N	3.3	999.0	83	10.0
2025-08-02	28.9	20.5	20.34	0	SSE	3.7	996.5	84	9.5
2025-08-03	30.4	0.0	21.10	0	SSE	2.6	1000.1	77	8.5
2025-08-04	31.3	0.0	26.14	0	S	4.3	1002.5	66	3.3
2025-08-05	32.1	0.0	25.58	0	SSE	3.2	1001.6	67	4.5
2025-08-06	32.3	0.0	23.20	0	SSE	2.4	999.8	68	7.5
2025-08-07	29.5	0.0	12.16	0	N	2.1	995.4	76	8.8
2025-08-08	28.6	3.0	17.46	0	NW	2.6	998.7	71	5.5
2025-08-09	28.4	0.0	18.21	0	SSE	2.7	1004.0	70	8.0
2025-08-10	26.3	25.5	4.32	0	S	4.1	1002.8	90	10.0
2025-08-11	27.1	11.5	7.97	0	S	5.6	1003.8	90	9.8
2025-08-12	28.2	1.0	6.88	0	SSW	4.4	1007.7	83	10.0
2025-08-13	27.9	0.0	17.21	0	E	2.4	1013.5	76	9.3
2025-08-14	27.8	0.0	20.39	0	S	2.6	1014.2	71	8.3
2025-08-15	28.7	0.0	24.42	0	S	2.9	1011.2	73	5.0
2025-08-16	28.8	1.0	19.08	0	S	3.1	1011.1	80	8.0
2025-08-17	29.8	0.0	22.79	0	SSE	3.2	1010.4	77	6.3
2025-08-18	31.0	0.0	22.43	0	SSE	2.5	1011.5	68	7.8
2025-08-19	29.9	0.0	22.92	0	SE	2.8	1009.6	76	2.0
2025-08-20	30.4	0.0	23.70	0	SSE	2.7	1007.5	72	3.5
2025-08-21	31.3	0.0	23.14	0	SSE	2.5	1007.4	63	6.5
2025-08-22	30.3	0.0	15.55	0	SSE	2.2	1007.9	71	10.0
2025-08-23	30.4	0.0	21.77	0	SSE	2.6	1007.7	73	7.3
2025-08-24	31.3	0.0	23.05	0	NE	2.3	1008.9	70	3.8
2025-08-25	30.6	0.0	17.21	0	SSE	2.7	1010.9	71	8.5
2025-08-26	30.1	0.0	20.41	0	SSE	3.7	1009.1	75	3.0
2025-08-27	30.7	0.0	23.07	0	S	3.6	1006.1	67	3.8
2025-08-28	28.9	0.0	15.70	0	SSE	3.0	1011.0	63	6.8
2025-08-29	28.7	0.0	18.41	0	SSE	2.4	1012.1	76	6.5
2025-08-30	31.6	0.0	23.26	0	S	2.5	1010.5	67	4.0
2025-08-31	30.9	0.0	21.83	0	SE	2.7	1010.3	73	1.3

データの概要

モデルの検討

気温を説明する 5 種類の線形回帰モデル

モデル 1 : 気温 = F(気圧)


モデル 2 : 気温 = F(日射)

モデル 3 : 気温 = F(気圧, 日射)


モデル 4 : 気温 = F(気圧, 日射, 湿度)

モデル 5 : 気温 = F(気圧, 日射, 雲量)


関連するデータの散布図




モデル 1 の推定結果



モデル 2 の推定結果



モデル3の推定結果



観測値とあてはめ値の比較




Table 2: 決定係数によるモデルの比較

変数	モデル 1		モデル 2		モデル 3		モデル 4		モデル 5	
	係数	標準誤差	係数	標準誤差	係数	標準誤差	係数	標準誤差	係数	標準誤差
気圧	0.01	0.057			-0.04	0.037	-0.05	0.035	-0.05	0.038
日射			0.22	0.034	0.22	0.034	0.15	0.043	0.21	0.047
湿度							-0.09	0.035		
雲量									-0.06	0.102
R ²	0.002		0.585		0.604		0.678		0.609	
Adjusted R ²	-0.032		0.571		0.576		0.642		0.566	

Abbreviations: CI = Confidence Interval, SE = Standard Error

決定係数によるモデルの比較

あてはめ値の性質

あてはめ値

- さまざまな表現

$$\begin{aligned}
 \hat{y} &= X\hat{\beta} \\
 (\hat{\beta} &= (X^T X)^{-1} X^T y \text{を代入}) \\
 &= X(X^T X)^{-1} X^T y
 \end{aligned} \tag{A}$$

$$\begin{aligned}
 (y &= X\beta + \epsilon \text{を代入}) \\
 &= X(X^T X)^{-1} X^T X\beta + X(X^T X)^{-1} X^T \epsilon \\
 &= X\beta + X(X^T X)^{-1} X^T \epsilon
 \end{aligned} \tag{B}$$

- (A) あてはめ値は 観測値の重み付けの和 で表される
- (B) あてはめ値と観測値は 誤差項 の寄与のみ異なる

あてはめ値と誤差

- 残差と誤差の関係

$$\begin{aligned}
\hat{\epsilon} &= y - \hat{y} \\
&= \epsilon - X(X^T X)^{-1} X^T \epsilon \\
&= (I - X(X^T X)^{-1} X^T) \epsilon
\end{aligned} \tag{C}$$

– (C) 残差は **誤差の重み付けの和** で表される

ハット行列

ハット行列

$$H = X(X^T X)^{-1} X^T$$

- ハット行列 H による表現

$$\begin{aligned}
\hat{y} &= Hy \\
\hat{\epsilon} &= (I - H)\epsilon
\end{aligned}$$

– あてはめ値や残差は H を用いて簡潔に表現される

ハット行列の性質

- 観測データ (デザイン行列) のみで計算される
- 観測データと説明変数の関係を表す
- 対角成分 (**テコ比**; leverage) は観測データが自身の予測に及ぼす影響の度合を表す

$$\hat{y}_j = (H)_{jj} y_j + (\text{それ以外のデータの寄与})$$

- $(A)_{ij}$ は行列 A の (i, j) 成分
- テコ比が小さい：他のデータでも予測が可能
- テコ比が大きい：他のデータでは予測が困難

推定量の統計的性質

最小二乗推定量の性質

- 推定量と誤差の関係

$$\begin{aligned}\hat{\beta} &= (X^T X)^{-1} X^T y \\ &= (X^T X)^{-1} X^T (X\beta + \epsilon) \\ &= (X^T X)^{-1} X^T X\beta + (X^T X)^{-1} X^T \epsilon \\ &= \beta + (X^T X)^{-1} X^T \epsilon\end{aligned}$$

- 誤差の分布によらない最小二乗推定量の重要な性質

正規分布の性質

正規分布の再生性

正規分布に従う独立な確率変数の和は正規分布に従う

- 正規分布の重要な性質
- 誤差が正規分布に従うならば最小二乗推定量の分布が評価できる

推定量の分布

- 誤差の仮定：独立，平均 0 分散 σ^2 の正規分布
- 推定量は以下の多変量正規分布に従う

$$\begin{aligned}\mathbb{E}[\hat{\beta}] &= \mathbb{E}[\beta + (X^T X)^{-1} X^T \epsilon] = \beta \\ \text{Cov}(\hat{\beta}) &= \mathbb{E}[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T] = \sigma^2 (X^T X)^{-1}\end{aligned}$$

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (X^T X)^{-1})$$

分散の推定

- 通常 σ^2 は未知, 必要な場合には不偏分散で代用

$$\hat{\sigma}^2 = \frac{S}{n-p-1} = \frac{1}{n-p-1} \hat{\epsilon}^T \hat{\epsilon} = \frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2$$

- これらの性質を利用してモデルの評価を行う

実習

誤差の評価

寄与率 (再掲)

- 決定係数 (R-squared)
 - 回帰式で説明できるばらつきの比率

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- 自由度調整済み決定係数 (adjusted R-squared)
 - 決定係数を不偏分散で補正

$$\bar{R}^2 = 1 - \frac{\frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

各係数の推定量の分布

- 推定された回帰係数の精度を評価
 - 誤差 ϵ の分布は平均 0 分散 σ^2 の正規分布
 - $\hat{\beta}$ の分布: $p+1$ 変量正規分布

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (X^T X)^{-1})$$

- $\hat{\beta}_j$ の分布: 1 変量正規分布

$$\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2 ((X^T X)^{-1})_{jj}) = \mathcal{N}(\beta_j, \sigma^2 \zeta_j^2)$$

* $(A)_{jj}$ は行列 A の (j, j) (対角) 成分

標準誤差

- 標準誤差 (standard error)
 - $\hat{\beta}_j$ の標準偏差の推定量

$$\text{s.e.}(\hat{\beta}_j) = \hat{\sigma}\zeta_j = \sqrt{\frac{1}{n-p-1} \sum_{i=1}^n \tilde{\epsilon}_i^2} \cdot \sqrt{((X^\top X)^{-1})_{jj}}$$

- 未知母数 σ^2 は不偏分散 $\hat{\sigma}^2$ で推定
- $\hat{\beta}_j$ の精度の評価指標

実習

係数の評価

t 統計量

回帰係数の分布に関する定理

t 統計量 (t -statistic)

$$t = \frac{\hat{\beta}_j - \beta_j}{\text{s.e.}(\hat{\beta}_j)} = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}\zeta_j}$$

は自由度 $n-p-1$ の t 分布に従う

- 証明には以下の性質を用いる
 - $\hat{\sigma}^2$ と $\hat{\beta}$ は独立となる
 - $(\hat{\beta}_j - \beta_j)/(\sigma\zeta_j)$ は標準正規分布に従う
 - $(n-p-1)\hat{\sigma}^2/\sigma^2 = S(\hat{\beta})/\sigma^2$ は自由度 $n-p-1$ の χ^2 分布に従う

t 統計量による検定

- 回帰係数 β_j が回帰式に寄与するか否かを検定
 - 帰無仮説 $H_0 : \beta_j = 0$ (t 統計量が計算できる)
 - 対立仮説 $H_1 : \beta_j \neq 0$
- p 値 : 確率変数の絶対値が $|t|$ を超える確率

- $f(x)$ は自由度 $n-p-1$ の t 分布の確率密度関数

$$(p \text{ 値}) = 2 \int_{|t|}^{\infty} f(x) dx \quad (\text{両側検定})$$

- 帰無仮説 H_0 が正しいければ p 値は小さくならない

実習

モデルの評価

平方和の分解 (再掲)

- いろいろなばらつき
 - $S_y = (y - \bar{y})^T (y - \bar{y})$: 目的変数のばらつき
 - $S = (y - \hat{y})^T (y - \hat{y})$: 残差のばらつき ($\hat{\epsilon}^T \hat{\epsilon}$)
 - $S_r = (\hat{y} - \bar{y})^T (\hat{y} - \bar{y})$: あてはめ値 (回帰) のばらつき
- 3つのばらつき (平方和) の関係

$$(y - \bar{y})^T (y - \bar{y}) = (y - \hat{y})^T (y - \hat{y}) + (\hat{y} - \bar{y})^T (\hat{y} - \bar{y})$$

$$S_y = S + S_r$$

F 統計量

ばらつきの比に関する定理

$\beta_1 = \dots = \beta_p = 0$ ならば F 統計量 (F -statistic)

$$F = \frac{\frac{1}{p} S_r}{\frac{1}{n-p-1} S} = \frac{n-p-1}{p} \frac{R^2}{1-R^2}$$

は自由度 $p, n-p-1$ の F 分布に従う

- 証明には以下の性質を用いる
 - S_r と S は独立となる
 - S_r/σ^2 は自由度 p の χ^2 分布に従う
 - S/σ^2 は自由度 $n-p-1$ の χ^2 分布に従う

F 統計量を用いた検定

- 説明変数のうち 1 つでも役に立つか否かを検定
 - 帰無仮説 $H_0 : \beta_1 = \dots = \beta_p = 0$ (S_r が χ^2 分布になる)
 - 対立仮説 $H_1 : \exists j \beta_j \neq 0$
- p 値 : 確率変数の値が F を超える確率
 - $f(x)$ は自由度 $p, n-p-1$ の F 分布の確率密度関数

$$(p \text{ 値}) = \int_F^{\infty} f(x) dx \quad (\text{片側検定})$$

- 帰無仮説 H_0 が正しいければ p 値は小さくならない

実習

次回の予定

- 第 1 回 : 回帰モデルの考え方と推定
- 第 2 回 : モデルの評価
- 第 3 回 : モデルによる予測と発展的なモデル