

回帰分析

予測と発展的なモデル

村田 昇

講義の内容

- 第1回: 回帰モデルの考え方と推定
- 第2回: モデルの評価
- 第3回: モデルによる予測と発展的なモデル

回帰分析の復習

線形回帰モデル

- 目的変数 を 説明変数 で説明する関係式を構成
 - 説明変数: $x_1, \dots, x_p$ (p 次元)
 - 目的変数: y (1 次元)
- 回帰係数 $\beta_0, \beta_1, \dots, \beta_p$ を用いた一次式

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

- 誤差項 を含む確率モデルで観測データを表現

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \epsilon_i \quad (i = 1, \dots, n)$$

問題設定

- 確率モデル

$$y = X\beta + \epsilon, \quad \epsilon \sim \text{確率分布}$$

- 式の評価：残差平方和 の最小化による推定

$$S(\beta) = (y - X\beta)^T(y - X\beta)$$

解とその一意性

- 解の条件：正規方程式

$$X^T X \beta = X^T y$$

- 解の一意性：Gram 行列 $X^T X$ が正則

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

解析の事例

気温に影響を与える要因の分析

- 気象庁より取得した東京の気候データ (再掲)
 - 気象庁 <https://www.data.jma.go.jp/gmd/risk/obsdl/index.php>

データの概要


モデルの検討

- 気温を説明する 5 種類の線形回帰モデル
 - モデル 1：気温 = F(気圧)
 - モデル 2：気温 = F(日射)
 - モデル 3：気温 = F(気圧, 日射)
 - モデル 4：気温 = F(気圧, 日射, 湿度)
 - モデル 5：気温 = F(気圧, 日射, 雲量)

Table 1: 東京の8月の気候データ

日付	気温	降雨	日射	降雪	風向	風速	気圧	湿度	雲量
2025-08-01	26.4	6.0	9.16	0	N	3.3	999.0	83	10.0
2025-08-02	28.9	20.5	20.34	0	SSE	3.7	996.5	84	9.5
2025-08-03	30.4	0.0	21.10	0	SSE	2.6	1000.1	77	8.5
2025-08-04	31.3	0.0	26.14	0	S	4.3	1002.5	66	3.3
2025-08-05	32.1	0.0	25.58	0	SSE	3.2	1001.6	67	4.5
2025-08-06	32.3	0.0	23.20	0	SSE	2.4	999.8	68	7.5
2025-08-07	29.5	0.0	12.16	0	N	2.1	995.4	76	8.8
2025-08-08	28.6	3.0	17.46	0	NW	2.6	998.7	71	5.5
2025-08-09	28.4	0.0	18.21	0	SSE	2.7	1004.0	70	8.0
2025-08-10	26.3	25.5	4.32	0	S	4.1	1002.8	90	10.0
2025-08-11	27.1	11.5	7.97	0	S	5.6	1003.8	90	9.8
2025-08-12	28.2	1.0	6.88	0	SSW	4.4	1007.7	83	10.0
2025-08-13	27.9	0.0	17.21	0	E	2.4	1013.5	76	9.3
2025-08-14	27.8	0.0	20.39	0	S	2.6	1014.2	71	8.3
2025-08-15	28.7	0.0	24.42	0	S	2.9	1011.2	73	5.0
2025-08-16	28.8	1.0	19.08	0	S	3.1	1011.1	80	8.0
2025-08-17	29.8	0.0	22.79	0	SSE	3.2	1010.4	77	6.3
2025-08-18	31.0	0.0	22.43	0	SSE	2.5	1011.5	68	7.8
2025-08-19	29.9	0.0	22.92	0	SE	2.8	1009.6	76	2.0
2025-08-20	30.4	0.0	23.70	0	SSE	2.7	1007.5	72	3.5
2025-08-21	31.3	0.0	23.14	0	SSE	2.5	1007.4	63	6.5
2025-08-22	30.3	0.0	15.55	0	SSE	2.2	1007.9	71	10.0
2025-08-23	30.4	0.0	21.77	0	SSE	2.6	1007.7	73	7.3
2025-08-24	31.3	0.0	23.05	0	NE	2.3	1008.9	70	3.8
2025-08-25	30.6	0.0	17.21	0	SSE	2.7	1010.9	71	8.5
2025-08-26	30.1	0.0	20.41	0	SSE	3.7	1009.1	75	3.0
2025-08-27	30.7	0.0	23.07	0	S	3.6	1006.1	67	3.8
2025-08-28	28.9	0.0	15.70	0	SSE	3.0	1011.0	63	6.8
2025-08-29	28.7	0.0	18.41	0	SSE	2.4	1012.1	76	6.5
2025-08-30	31.6	0.0	23.26	0	S	2.5	1010.5	67	4.0
2025-08-31	30.9	0.0	21.83	0	SE	2.7	1010.3	73	1.3

関連するデータの散布図



観測値とあてはめ値の比較




Table 2: 決定係数によるモデルの比較

	モデル 1	モデル 2	モデル 3	モデル 4	モデル 5
変数	係数 (SE) [†]	係数 (SE) [†]	係数 (SE) [†]	係数 (SE) [†]	係数 (SE) [†]
気圧	0.01(0.057)		-0.04(0.037)	-0.05(0.035)	-0.05(0.038)
日射		0.22(0.034)***	0.22(0.034)***	0.15(0.043)**	0.21(0.047)***
湿度				-0.09(0.035)*	
雲量					-0.06(0.102)
R ²	0.002	0.585	0.604	0.678	0.609
Adjusted R ²	-0.032	0.571	0.576	0.642	0.566

[†]*p<0.05; **p<0.01; ***p<0.001

Abbreviation: SE = 標準誤差

寄与率

- 決定係数 (R-squared)

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- 自由度調整済み決定係数 (adjusted R-squared)

$$\bar{R}^2 = 1 - \frac{\frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

– 不偏分散で補正

決定係数 (R^2 ・Adjusted R^2) によるモデルの比較

F 統計量による検定

- 説明変数のうち 1 つでも役に立つか否かを検定する
 - 帰無仮説 $H_0: \beta_1 = \dots = \beta_p = 0$
 - 対立仮説 $H_1: \exists j \beta_j \neq 0$ (少なくとも 1 つは役に立つ)
- F 統計量: 決定係数 (または残差) を用いて計算

$$F = \frac{n-p-1}{p} \frac{R^2}{1-R^2}$$

- p 値: 自由度 $p, n-p-1$ の F 分布で計算

Table 3: F 統計量によるモデルの比較

変数	モデル 1 係数 (SE) ¹	モデル 2 係数 (SE) ¹	モデル 3 係数 (SE) ¹	モデル 4 係数 (SE) ¹	モデル 5 係数 (SE) ¹
気圧	0.01(0.057)		-0.04(0.037)	-0.05(0.035)	-0.05(0.038)
日射		0.22(0.034)***	0.22(0.034)***	0.15(0.043)**	0.21(0.047)***
湿度				-0.09(0.035)*	
雲量					-0.06(0.102)
R ²	0.002	0.585	0.604	0.678	0.609
Statistic	0.060	41.0	21.4	18.9	14.0
p-value	0.8	<0.001	<0.001	<0.001	<0.001

¹*p<0.05; **p<0.01; ***p<0.001

Abbreviation: SE = 標準誤差

F 統計量によるモデルの比較

t 統計量による検定

- 回帰係数 β_j が回帰式に寄与するか否かを検定する
 - 帰無仮説 $H_0 : \beta_j = 0$
 - 対立仮説 $H_1 : \beta_j \neq 0$ (β_j は役に立つ)
- t 統計量 : 各係数ごと, ζ は $(X^T X)^{-1}$ の対角成分

$$t = \frac{\hat{\beta}_j}{\hat{\sigma}\zeta_j}$$

- p 値 : 自由度 $n-p-1$ の t 分布を用いて計算

t 統計量によるモデルの比較

診断プロットによる評価

- 回帰モデルのあてはまりを視覚的に評価
 - **Residuals vs Fitted** : あてはめ値 (予測値) と残差の関係 (誤差の均一性)
 - **Normal Q-Q** : 標準化残差と標準正規分布の比較 (残差の正規性)
 - **Scale-Location** : あてはめ値と標準化残差の関係 (分散の均一性)
 - **Residuals vs Leverage** : 標準化残差とテコ比の関係 (外れ値)


Table 4: t 統計量によるモデルの比較

変数	モデル 3				モデル 4				モデル 5			
	係数	SE	t 統計量	p 値 ¹	係数	SE	t 統計量	p 値 ¹	係数	SE	t 統計量	p 値 ¹
(Intercept)	69	37.4	1.83	0.078	86	35.1	2.46	0.021*	72	38.3	1.87	0.072
気圧	-0.04	0.037	-1.15	0.3	-0.05	0.035	-1.53	0.14	-0.05	0.038	-1.19	0.2
日射	0.22	0.034	6.53	<0.001***	0.15	0.043	3.53	0.002**	0.21	0.047	4.37	<0.001***
湿度					-0.09	0.035	-2.49	0.019*				
雲量									-0.06	0.102	-0.577	0.6


¹*p<0.05; **p<0.01; ***p<0.001

Abbreviation: SE = 標準誤差


モデル 3 の診断プロット



モデル 4 の診断プロット



モデル 5 の診断プロット



回帰モデルによる予測

予測

- 新しいデータ (説明変数) x に対する **予測値**

$$\hat{y} = (1, x^\top)\hat{\beta}, \quad \hat{\beta} = (X^\top X)^{-1}X^\top y$$

- 予測値は元データの目的変数の重み付け線形和

$$\hat{y} = w(x)^\top y, \quad w(x)^\top = (1, x^\top)(X^\top X)^{-1}X^\top$$

- 重みは元データと新規データの説明変数で決定

予測値の性質

- 推定量は以下の性質をもつ多変量正規分布

$$\begin{aligned}\mathbb{E}[\hat{\beta}] &= \beta \\ \text{Cov}(\hat{\beta}) &= \sigma^2(X^\top X)^{-1}\end{aligned}$$

- この性質を利用して以下の3つの値の違いを評価

$$\begin{aligned}y &= (1, x^\top)\beta + \epsilon && \text{(観測値)} \\ \tilde{y} &= (1, x^\top)\beta && \text{(最適な予測値)} \\ \hat{y} &= (1, x^\top)\hat{\beta} && \text{(回帰式による予測値)}\end{aligned}$$

- $\hat{y}$ と y は独立な正規分布に従うことに注意

信頼区間

最適な予測値との差

- 差の分布は以下の平均・分散をもつ正規分布に従う

$$\begin{aligned}\mathbb{E}[\tilde{y} - \hat{y}] &= (1, x^\top)\beta - (1, x^\top)\mathbb{E}[\hat{\beta}] = 0 \\ \text{Var}(\tilde{y} - \hat{y}) &= \underbrace{\sigma^2(1, x^\top)(X^\top X)^{-1}(1, x^\top)^\top}_{\hat{\beta} \text{ の推定誤差による分散}} = \sigma^2 \gamma_c(x)^2\end{aligned}$$

- 標準化による表現

$$\frac{\tilde{y} - \hat{y}}{\sigma\gamma_c(x)} \sim \mathcal{N}(0, 1)$$

信頼区間

- 未知の分散を不偏分散で推定

$$Z = \frac{\tilde{y} - \hat{y}}{\hat{\sigma}\gamma_c(x)} \sim \mathcal{T}(n-p-1) \quad (t \text{ 分布})$$

- 確率 α の信頼区間

$$\mathcal{I}_\alpha^c = (\hat{y} - C_\alpha \hat{\sigma}\gamma_c(x), \hat{y} + C_\alpha \hat{\sigma}\gamma_c(x))$$

$$P(|Z| < C_\alpha | Z \sim \mathcal{T}(n-p-1)) = \alpha$$

– 最適な予測値 $\tilde{y}$ が入ることが期待される区間

予測区間

観測値との差

- 差の分布は以下の平均・分散をもつ正規分布に従う

$$\begin{aligned} \mathbb{E}[y - \hat{y}] &= (1, x^\top)\beta + \mathbb{E}[\epsilon] - (1, x^\top)\mathbb{E}[\hat{\beta}] = 0 \\ \text{Var}(y - \hat{y}) &= \underbrace{\sigma^2(1, x^\top)(X^\top X)^{-1}(1, x^\top)^\top}_{\hat{\beta} \text{ の推定誤差による分散}} + \underbrace{\sigma^2}_{\text{誤差の分散}} = \sigma^2\gamma_p(x)^2 \end{aligned}$$

- 標準化による表現

$$\frac{y - \hat{y}}{\sigma\gamma_p(x)} \sim \mathcal{N}(0, 1)$$

予測区間

- 未知の分散を不偏分散で推定

$$Z = \frac{y - \hat{y}}{\hat{\sigma}\gamma_p(x)} \sim \mathcal{T}(n-p-1) \quad (t \text{ 分布})$$

- 確率 α の予測区間

$$\mathcal{J}_\alpha^p = (\hat{y} - C_\alpha \hat{\sigma}\gamma_p(x), \hat{y} + C_\alpha \hat{\sigma}\gamma_p(x))$$

$$P(|Z| < C_\alpha | Z \sim \mathcal{T}(n-p-1)) = \alpha$$

- 観測値 y が入ることが期待される区間
- $\gamma_p > \gamma_c$ なので信頼区間より広くなる

実習

発展的なモデル

非線形性を含むモデル

- 目的変数 y
- 説明変数 $x_1, \dots, x_p$
- 説明変数の追加で対応可能
 - 交互作用 (交差項) : $x_i x_j$ のような説明変数の積
 - 非線形変換 : $\log(x_k)$ のような関数による変換

カテゴリカル変数を含むモデル

- 数値ではないデータの例
 - 悪性・良性
 - 血液型 (A 型, B 型, AB 型, O 型)
- 適切な方法で数値に変換して対応
 - 2 値の場合は 1, 0 (真, 偽) を割り当てる
 - * 悪性 : 1
 - * 良性 : 0

– 3 値以上の場合は **ダミー変数** を利用する (カテゴリ数-1 個)

- * A 型 : (1,0,0)
- * B 型 : (0,1,0)
- * O 型 : (0,0,1)
- * AB 型 : (0,0,0)

実習

次回の予定

- 第 1 回: 主成分分析の考え方
- 第 2 回: 分析の評価と視覚化