判別分析

分析の評価

村田 昇

講義の内容

- 第 1 回：判別分析の考え方
- **第 2 回：分析の評価**

判別分析の復習

判別分析

- 個体の特徴量から その個体の属するクラスを予測する関係式を構成
- **事前確率**：$\pi_k = P(Y = k)$ (prior probability)
  - $X = x$ が与えられる前に予測されるクラス
- **事後確率**：$p_k(x)$ (posterior probability)
  - $X = x$ が与えられた後に予測されるクラス

$$p_k(x) = P(Y = k|X = x)$$

  - 所属する確率が最も高いクラスに個体を分類

判別関数

- 判別の手続き
  - 説明変数 $X = x$ の取得
  - 事後確率 $p_k(x)$ の計算
  - 事後確率最大のクラスにデータを分類
- **判別関数**：$\delta_k(x)$ $(k = 1, \ldots, K)$

$$p_k(x) < p_l(x) \Leftrightarrow \delta_k(x) < \delta_l(x)$$

  事後確率の順序を保存する計算しやすい関数
- 判別関数 $\delta_k(x)$ を最大化するようなクラス k に分類

線形判別

- $f_k(x)$ の仮定
  - q 変量正規分布の密度関数
  - 平均ベクトル μ_k：クラスごとに異なる
  - 共分散行列 Σ：**すべてのクラスで共通**

$$f_k(x) = \frac{1}{(2\pi)^{q/2}\sqrt{\det \Sigma}} \exp\left(-\frac{1}{2}(x-\mu_k)^{\mathsf{T}}\Sigma^{-1}(x-\mu_k)\right)$$

- 線形判別関数：x の 1 次式

$$\delta_k(x) = x^{\mathsf{T}}\Sigma^{-1}\mu_k - \frac{1}{2}\mu_k^{\mathsf{T}}\Sigma^{-1}\mu_k + \log \pi_k$$

2 次判別

- $f_k(x)$ の仮定
  - q 変量正規分布の密度関数
  - 平均ベクトル μ_k：クラスごとに異なる
  - 共分散行列 Σ_k：**クラスごとに異なる**

$$f_k(x) = \frac{1}{(2\pi)^{q/2}\sqrt{\det \Sigma_k}} \exp\left(-\frac{1}{2}(x-\mu_k)^{\mathsf{T}}\Sigma_k^{-1}(x-\mu_k)\right)$$

- 2 次判別関数：x の 2 次式

$$\delta_k(x) = -\frac{1}{2}\log\det \Sigma_k - \frac{1}{2}(x-\mu_k)^{\mathsf{T}}\Sigma_k^{-1}(x-\mu_k) + \log \pi_k$$

Fisher の線形判別

- 新しい特徴量 $Z = \alpha^{\mathsf{T}}X$ を考える
- 良い Z の基準
  - クラス内では集まっているほど良い ($\alpha^{\mathsf{T}}W\alpha$ は小)
  - クラス間では離れているほど良い ($\alpha^{\mathsf{T}}B\alpha$ は大)
- Fisher の基準

$$\text{maximize} \quad \alpha^{\mathsf{T}}B\alpha \quad \text{s.t.} \quad \alpha^{\mathsf{T}}W\alpha = \text{const.}$$

  - α は $W^{-1}B$ の第 1 から第 $K-1$ 固有ベクトル
  - 判別方法: 特徴量の距離を用いる
  - $d_k = \sum_{l=1}^{K-1}(\alpha_l^{\mathsf{T}}x - \alpha_l^{\mathsf{T}}\mu_k)^2$ が最小のとなるクラス k に判別

2 値判別分析の評価

誤り率

- 単純な誤り

$$(\text{誤り率}) = \frac{(\text{誤って判別されたデータ数})}{(\text{全データ数})}$$

- 判別したいラベル：陽性 (positive)
  - **真陽性**：正しく陽性と判定 (true positive; TP)
  - **偽陽性**：誤って陽性と判定 (false positive; FP) (**第 I 種過誤**)
  - **偽陰性**：誤って陰性と判定 (false negative; FN) (**第 II 種過誤**)
  - **真陰性**：正しく陰性と判定 (true negative; TN)

混同行列

	真値は陽性	真値は陰性
判別は陽性	真陽性 (True Positive)	偽陽性 (False Positive)
判別は陰性	偽陰性 (False Negative)	真陰性 (True Negative)

- **confusion matrix**
- 各条件にあてはまるデータ数を記載
- 転置で書く流儀もあるので注意 (次頁)

混同行列 (転置したもの)

	判別は陽性	判別は陰性
真値は陽性	真陽性 (True Positive)	偽陰性 (False Negative)
真値は陰性	偽陽性 (False Positive)	真陰性 (True Negative)

- パターン認識や機械学習で多く見られた書き方
- 誤差行列 (error matrix) とも呼ばれる

基本的な評価基準

- 定義

$$(\text{真陽性率}) = \frac{TP}{TP+FN} \qquad (\text{true positive rate})$$
$$(\text{真陰性率}) = \frac{TN}{FP+TN} \qquad (\text{true negative rate})$$
$$(\text{適合率}) = \frac{TP}{TP+FP} \qquad (\text{precision})$$
$$(\text{正答率}) = \frac{TP+TN}{TP+FP+TN+FN} \qquad (\text{accuracy})$$

- 別名 (分野で異なるので注意)
  - 感度 (sensitivity) あるいは 再現率 (recall)

$$(\text{真陽性率}) = \frac{TP}{TP+FN}$$

  - 特異度 (specificity)

$$(\text{真陰性率}) = \frac{TN}{FP+TN}$$

  - 精度 (accuracy)

$$(\text{正答率}) = \frac{TP+TN}{TP+FP+TN+FN}$$

F-値

- 定義 (**F-measure, F-score**)

$$F_1 = \frac{2}{1/(\text{再現率}) + 1/(\text{適合率})}$$
$$F_\beta = \frac{\beta^2+1}{\beta^2/(\text{再現率}) + 1/(\text{適合率})}$$

  - 再現率 (真陽性率) と適合率の (重み付き) 調和平均

$$\text{調和平均} < \text{相乗平均} < \text{相加平均}$$

Cohen の kappa 値

- 定義 (Cohen's **kappa measure**)

$$
\begin{aligned}
p_o &= \frac{TP+TN}{TP+FP+TN+FN} \qquad \text{(accuracy)} \\
p_e &= \frac{TP+FP}{TP+FP+TN+FN} \cdot \frac{TP+FN}{TP+FP+TN+FN} \\
&\quad + \frac{FN+TN}{TP+FP+TN+FN} \cdot \frac{FP+TN}{TP+FP+TN+FN} \\
\kappa &= \frac{p_o-p_e}{1-p_e} = 1 - \frac{1-p_o}{1-p_e}
\end{aligned}
$$

  - 観測された精度と偶然の精度の比較

受信者動作特性曲線

- **ROC 曲線** (receiver operating characteristic curve)
- 2 値判別関数 δ を用いた判定方法の一般形
  (c は事前確率に依存する項とも考えられる)

$$
H(x;c) = \begin{cases} \text{陽性}, & \delta(x) > c \\ \text{陰性}, & \text{それ以外} \end{cases}
$$

- 真陽性率と偽陽性率

$$
\begin{aligned}
\mathrm{TPR}(c) &= P(\text{陽性を正しく陽性と判別}) \\
\mathrm{FPR}(c) &= P(\text{陰性を誤って陽性と判別}) \\
&= 1 - P(\text{陰性を正しく陰性と判別})
\end{aligned}
$$

- **ROC 曲線**： $H(x;c)$ の c を自由に動かし x 軸に偽陽性率，y 軸に真陽性率を描画したもの
  - 一般に ROC 曲線は $(0,0)$ と $(1,1)$ を結ぶ右肩上りの曲線
  - 理想的な判別関数は $(0,1)$(完全な判別) を通る
  - 曲線と x 軸で囲まれた面積が広い $\Leftrightarrow$ 良い判別方法
- **AUC**：上記の面積 (area under the ROC curve)
  - ROC 曲線を数量化する方法の一つ
  - 判別関数の良さ (2 値判別の難しさ) を測る基準の一つ

実習

予測誤差

訓練誤差と予測誤差

- **訓練誤差**：既知データに対する誤り (training error)
- **予測誤差**：未知データに対する誤り (predictive error)
- 訓練誤差は予測誤差より良くなることが多い
- 既知データの判別に特化している可能性がある
  - 過適応 (over-fitting)
  - 過学習 (over-training)
- 予測誤差が小さい $\Leftrightarrow$ 良い判別方法

交叉検証

- データを訓練データと試験データに分割して用いる
  - **訓練データ**：判別関数を構成する (training data)
  - **試験データ**：予測精度を評価する (test data)
- データの分割に依存して予測誤差の評価が偏る
- 偏りを避けるために複数回分割を行ない評価する
- “交差” と書く場合もある

交叉検証法

- **cross-validation (CV)**
- k 重交叉検証法 (k-fold cross-validation; k-fold CV)
  - n 個のデータを k ブロックにランダムに分割
  - 第 i ブロックを除いた k–1 ブロックで判別関数を推定
  - 除いておいた第 i ブロックで予測誤差を評価
  - $i = 1, \ldots, k$ で繰り返し k 個の予測誤差で評価 (平均や分散)
- leave-one-out 法 (leave-one-out CV; LOO-CV)
  - $k = n$ として上記を実行

実習

次回の予定

- **第 1 回：クラスタ分析の考え方と階層的方法**
- 第 2 回：非階層的方法と分析の評価