

時系列解析

基本的なモデル

村田 昇

2020.12.18

講義の予定

- 第 1 日: 時系列のモデル
- 第 2 日: モデルの推定と予測

時系列解析の概要

時系列解析とは

- 時系列データ
 - 時間軸に沿って観測されたデータ
 - 観測の順序に意味がある
 - 異なる時点間での観測データの従属関係が重要
 - 独立性にもとづく解析は行えない
(そのままでは大数の法則や中心極限定理は使えない)
- 時系列解析の目的
 - 時系列データの特徴を効果的に記述すること
 - 時系列モデルの推定と評価

時系列データ

- 統計学・確率論における表現: **確率過程**
時間を添え字として持つ確率変数列

$$X_t, t = 1, 2, \dots, T \quad (\text{あるいは } t = 0, 1, \dots, T)$$

- 時系列解析で利用される代表的な確率過程
 - ホワイトノイズ
 - ランダムウォーク
 - 自己回帰モデル (AR モデル)
 - 移動平均モデル (MA モデル)
 - 自己回帰移動平均モデル (ARMA モデル)

基本的なモデル

ホワイトノイズ

- 定義

平均 0, 分散 σ^2 である確率変数の確率分布 P からの独立かつ同分布な確率変数列

$$X_t = \epsilon_t, \quad \epsilon_t \stackrel{i.i.d.}{\sim} P$$

- 記号 $\text{WN}(0, \sigma^2)$ で表記することが多い

$$X_t \sim \text{WN}(0, \sigma^2)$$

- 独立であるため系列としての予測は不可能

トレンドのあるホワイトノイズ

- 定義

μ, α を定数として

$$X_t = \mu + \alpha t + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で定義される確率過程

- **トレンド** $\mu + \alpha t$ はより一般化されることもある
 - t の 1 次式 (上記の基本的な場合)
 - 高次の多項式
 - 非線形関数 (指数関数, 三角関数など)
- **平均** が時間とともに変動する時系列モデルの 1 つ

ランダムウォーク

- 定義

X_0 を定数もしくは確率変数として

$$X_t = X_{t-1} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で帰納的に定義される確率過程

- **分散** が時間とともに増加する時系列モデルの 1 つ
- 最も単純な **記憶** のあるモデル

実習

R: 時系列データの扱い

- 時系列のためのクラス: `ts` クラス
 - ベクトル (1 次元) データだが, 時間に関する情報が付加される
 - ベクトルからの変換: 関数 `ts()`
 - 多次元時系列も扱うことは可能
- 関数 `plot()` などの挙動はベクトルと異なる
 - プロットが既定値で折れ線
 - x 軸に時間の情報が表示
 - 通常は時間情報を利用して適切に処理してくれる
- より複雑な時系列を記述するためには `zoo` や `xts` などのパッケージがある

R: 関数 ts()

- 時系列クラス ts を作成する関数

```
ts(data = NA, start = 1, end = numeric(), frequency = 1)
## data: ベクトル, または行列 (データフレーム)
## start: 開始時刻
## end: 終了時刻
## frequency: 単位時間あたりの観測回数
ts(data = x, start = c(2020,1), frequency =12) # 月ごとのデータ
ts(data = x, start = c(2020,3), frequency =4) # 四半期ごとのデータ
```

– その他の詳細は ?ts

練習問題

- 指定された確率過程を生成し、図示を行いなさい
 - 平均 0, 分散 4 の正規分布に従うホワイトノイズ
 - 上記のホワイトノイズに初期値-1 で単位時刻あたり 1/20 で増加するトレンドを持つ確率過程
 - 上記のホワイトノイズから生成されるランダムウォーク

より一般的なモデル

自己回帰過程

- 定義 (次数 p ; AR(p), auto regressive の略)
 a_1, \dots, a_p を定数とし, X_1, \dots, X_p が初期値として与えられたとき,
$$X_t = a_1 X_{t-1} + \dots + a_p X_{t-p} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で帰納的に定義される確率過程
 - ランダムウォークの一般化
 - * $p = 1, a_1 = 1$ かつ ϵ_t が独立同分布ならランダムウォーク
 - 忘却しながら記憶するモデル ($|a_i| < 1$ などの条件が必要)

移動平均過程

- 定義 (次数 q ; MA(q), moving average の略)
 b_1, \dots, b_q を定数とし, X_1, \dots, X_q が初期値として与えられたとき
$$X_t = b_1 \epsilon_{t-1} + \dots + b_q \epsilon_{t-q} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で定義される確率過程
 - 記憶のあるホワイトノイズ (構成する部品を記憶)

自己回帰平均移動過程

- 定義 (次数 (p, q) ; ARMA(p, q)
 $a_1, \dots, a_p, b_1, \dots, b_q$ を定数とし, $X_1, \dots, X_{\max\{p, q\}}$ が初期値として与えられたとき
$$X_t = a_1 X_{t-1} + \dots + a_p X_{t-p} + b_1 \epsilon_{t-1} + \dots + b_q \epsilon_{t-q} + \epsilon_t,$$

$$\epsilon_t \sim \text{WN}(0, \sigma^2)$$

で帰納的に定まる確率過程
 - AR(p) モデルは ARMA($p, 0$), MA(q) モデルは ARMA($0, q$)
 - 単純な形ながら異なる時点間の従属構造を柔軟に記述
 - 基本的な時系列モデルとして広く利用されている

実習

練習問題

- 平均 0, 分散 1 のホワイトノイズを用いて, 以下の指定された確率過程を生成し, 図示を行いなさい
 - 係数 $a_1 = 0.67, a_2 = 0.26$ を持つ AR(2) 過程
 - 係数 $b_1 = 0.44, b_2 = 0.08$ を持つ MA(2) 過程
 - 係数 $a_1 = 0.8, a_2 = -0.64, b_1 = -0.5$ を持つ ARMA(2,1) 過程

定常過程と非定常過程

弱定常性

- 確率過程 $X_t, t = 1, \dots, T$ が次の性質をもつ:
 - X_t の平均は時点 t によらない

$$\mathbb{E}[X_t] = \mu \quad (\text{時間の添字を持たない})$$

- X_t と X_{t+h} の共分散は時点 t によらず時差 h のみで定まる

$$\text{Cov}(X_t, X_{t+h}) = \gamma(h) \quad (\text{時間の添字を持たない})$$

- 特に X_t の分散は時点 t によらない ($h = 0$ の場合)

$$\text{Var}(X_t) = \gamma(0)$$

定常性と非定常性

- 定常でない確率過程は **非定常** であるという
- いろいろな確率過程の定常性
 - 定常: ホワイトノイズ, MA
 - 非定常: トレンドのあるホワイトノイズ, ランダムウォーク
 - 定常にも非定常にもなりうる: AR, ARMA

非定常過程の難しさ

- 性質を特徴付ける統計量が一般に観測値から得られない
 - 平均や分散などの基本的な統計量が時間によって変動する
 - 1 つの時系列から記述統計量の推測はできない
- 擬似相関の問題
 - 独立な時系列にも関わらず見掛けの相関が現れることがある
 - 2 つの独立なランダムウォークは高い確率で“相関”を持つ
 - <https://tylervigen.com/spurious-correlations>

非定常過程の取り扱い

- 定常過程とみなせるように変換したあと分析を実行

- 階差をとる変換

ランダムウォークは階差をとればホワイトノイズ (定常過程) となる

$$X_t = X_{t-1} + \epsilon_t \Rightarrow Y_t = X_t - X_{t-1} = \epsilon_t$$

- 対数変換

対数変換と階差で微小な比率の変動を取り出すことができる

$$X_t = (1 + \epsilon_t)X_{t-1} \Rightarrow Y_t = \log(X_t) - \log(X_{t-1}) = \log(1 + \epsilon_t) \simeq \epsilon_t$$

- トレンド成分+季節成分+変動成分への分解

適当な仮説のもとに取り扱いやすい成分の和に分解する

自己共分散・自己相関

自己共分散・自己相関

- 確率過程 X_t が **定常過程** の場合

- X_t と X_{t+h} の共分散は時点 t によらずラグ h のみで定まる

自己共分散 (定常過程の性質よりラグは $h \geq 0$ を考えればよい)

$$\text{Cov}(X_t, X_{t+h}) = \gamma(h)$$

- X_t と X_{t+h} の相関も t によらずラグ h のみで定まる

自己相関

$$\text{Cov}(X_t, X_{t+h})/\text{Var}(X_t) = \gamma(h)/\gamma(0)$$

- 異なる時点間での観測データの従属関係を要約するための最も基本的な統計量

標本自己共分散・標本自己相関

- 観測データ X_1, \dots, X_T からの推定

- ラグ h の自己共分散の推定: 標本自己共分散

$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (X_t - \bar{X})(X_{t+h} - \bar{X})$$

$\bar{X} = \frac{1}{T} \sum_{t=1}^T X_t$ は標本平均

- ラグ h での自己相関の推定: 標本自己相関

$$\hat{\gamma}(h)/\hat{\gamma}(0) = \frac{\sum_{t=1}^{T-h} (X_t - \bar{X})(X_{t+h} - \bar{X})}{\sum_{t=1}^T (X_t - \bar{X})^2}$$

実習

R: 関数 `acf()`

- 自己相関・自己共分散の計算

```
acf(x, lag.max = NULL,  
    type = c("correlation", "covariance", "partial"),  
    plot = TRUE, na.action = na.fail, demean = TRUE, ...)  
## x: 時系列データ  
## lag.max: 計算するラグの最大値  
## type: 標準は相関, 共分散と偏相関を選ぶこともできる  
## plot: 描画するか否か  
## na.action: 欠損値の処理, 標準は欠損を含むと計算しない  
## demean: 共分散の計算において平均を引くか否か
```

– 詳細は ?acf

練習問題

- 以下の問に答えなさい
 - 同じ AR 過程のモデルから生成した時系列の自己相関を比較しなさい (前の練習問題を利用すればよい)
 - MA 過程についても同様な比較を行いなさい
 - ARMA 過程についても同様な比較を行いなさい

次週の内容

- 第 1 日: 時系列のモデル
- 第 2 日: モデルの推定と予測