

時系列解析

時系列の基本モデル

村田 昇

講義概要

- 第 1 回 : 時系列の基本モデル
- 第 2 回 : モデルの推定と予測

時系列解析の例

データの概要

- 米国の航空機旅客量の変遷データ
 - `datasets::AirPassengers` (R に標準で収録)
 - 1949 年から 1960 年までの月別の集計データ
 - 出典

Box, G. E. P., Jenkins, G. M. and Reinsel, G. C. (1976) Time Series Analysis, Forecasting and Control. Third Edition. Holden-Day. Series G.

year	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
1949	112	118	132	129	121	135	148	148	136	119	104	118
1950	115	126	141	135	125	149	170	170	158	133	114	140
1951	145	150	178	163	172	178	199	199	184	162	146	166
1952	171	180	193	181	183	218	230	242	209	191	172	194
1953	196	196	236	235	229	243	264	272	237	211	180	201
1954	204	188	235	227	234	264	302	293	259	229	203	229
1955	242	233	267	269	270	315	364	347	312	274	237	278
1956	284	277	317	313	318	374	413	405	355	306	271	306
1957	315	301	356	348	355	422	465	467	404	347	305	336
1958	340	318	362	348	363	435	491	505	404	359	310	337
1959	360	342	406	396	420	472	548	559	463	407	362	405
1960	417	391	419	461	472	535	622	606	508	461	390	432

データのモデル化

モデルにもとづく予測

時系列解析の概要

時系列解析とは

- 時系列データ
 - 時間軸に沿って観測されたデータ




Figure 1: 航空機旅客量データ・自己相関・季節性の確認




Figure 2: 時系列の分解による表現




Figure 3: モデルの推定とあてはめ




Figure 4: 航空機旅客量の予測

- 観測の順序に意味がある
- 異なる時点間での観測データの従属関係が重要
- **独立性にもとづく解析は行えない**
 - * そのままでは大数の法則や中心極限定理は使えない

- 時系列解析の目的
 - 時系列データの特徴を効果的に記述すること
 - 時系列モデルの推定と評価

時系列データ

- 統計学・確率論における表現：**確率過程**
時間を添え字として持つ確率変数列

$$X_t, t = 1, 2, \dots, T \quad (\text{あるいは } t = 0, 1, \dots, T)$$

- 時系列解析で利用される代表的な確率過程
 - ホワイトノイズ
 - ランダムウォーク
 - 自己回帰モデル (AR モデル)
 - 移動平均モデル (MA モデル)
 - 自己回帰移動平均モデル (ARMA モデル)

基本的なモデル

ホワイトノイズ

- 定義
平均 0 分散 σ^2 である確率変数の確率分布 P からの独立かつ同分布な確率変数列

$$X_t = \epsilon_t, \quad \epsilon_t \stackrel{i.i.d.}{\sim} P$$

- 記号 $WN(0, \sigma^2)$ で表記することが多い

$$X_t \sim \text{WN}(0, \sigma^2)$$

- 独立であるため系列としての予測 (点推定) は不可能




Figure 5: ホワイトノイズ (標準正規分布)

トレンドのあるホワイトノイズ

- 定義

μ, α を定数として以下で定義される確率過程

$$X_t = \mu + \alpha t + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

- **トレンド** $\mu + \alpha t$ はより一般化されることもある
 - t の 1 次式 (上記の基本的な場合)
 - 高次の多項式
 - 非線形関数 (指数関数, 三角関数など)
- **平均** が時間とともに変動する時系列モデルの 1 つ

ランダムウォーク

- 定義

X_0 を定数もしくは確率変数として以下で帰納的に定義される確率過程

$$X_t = X_{t-1} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

- **分散** が時間とともに増加する時系列モデルの 1 つ
- 最も単純な **記憶** のあるモデル




Figure 6: トレンドのあるホワイトノイズ




Figure 7: ランダムウォーク

実習

より一般的なモデル

自己回帰過程

- 定義 (AR(p); 次数 p の auto regressive の略)

$a_1, \dots, a_p$ を定数とし $X_1, \dots, X_p$ が初期値として与えられたとき以下で帰納的に定義される確率過程

$$X_t = a_1 X_{t-1} + \dots + a_p X_{t-p} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

- ランダムウォークの一般化
 - * $p = 1, a_1 = 1$ かつ ϵ_t が独立同分布ならランダムウォーク
- 忘却しながら記憶するモデル ($|a_i| < 1$ などの条件が必要)




Figure 8: AR 過程

移動平均過程

- 定義 (MA(q); 次数 q の moving average の略)

$b_1, \dots, b_q$ を定数とし, $X_1, \dots, X_q$ が初期値として与えられたとき以下で帰納的に定義される確率過程

$$X_t = b_1 \epsilon_{t-1} + \dots + b_q \epsilon_{t-q} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

- 記憶のあるホワイトノイズ (構成する部品を記憶)

自己回帰移動平均過程

- 定義 (ARMA(p, q); 次数 (p, q))

$a_1, \dots, a_p, b_1, \dots, b_q$ を定数とし $X_1, \dots, X_{\max\{p, q\}}$ が初期値として与えられたとき以下で帰納的に定まる確率過程

$$\begin{aligned} X_t &= a_1 X_{t-1} + \dots + a_p X_{t-p} \\ &\quad + b_1 \epsilon_{t-1} + \dots + b_q \epsilon_{t-q} + \epsilon_t, \\ \epsilon_t &\sim \text{WN}(0, \sigma^2) \end{aligned}$$




Figure 9: MA 過程

- $AR(p)$ モデルは $ARMA(p, 0)$, $MA(q)$ モデルは $ARMA(0, q)$
- 単純な形ながら異なる時点間の従属構造を柔軟に記述
- 基本的な時系列モデルとして広く利用されている




Figure 10: ARMA 過程

実習

定常過程と非定常過程

弱定常性

- 確率過程 $X_t, t = 1, \dots, T$ が次の性質をもつ
 - X_t の平均は時点 t によらない

$$\mathbb{E}[X_t] = \mu \quad (\text{時間の添字を持たない})$$

- X_t と X_{t+h} の共分散は時点 t によらず時差 h のみで定まる

$$\text{Cov}(X_t, X_{t+h}) = \gamma(h) \quad (\text{時間の添字を持たない})$$

- 特に X_t の分散は時点 t によらない ($h = 0$ の場合)

$$\text{Var}(X_t) = \gamma(0), \quad (X_t \text{ は二乗可積分であることを仮定})$$

定常性と非定常性

- 定常でない確率過程は **非定常** であるという
- いろいろな確率過程の定常性
 - 定常: ホワイトノイズ, MA
 - 非定常: トレンドのあるホワイトノイズ, ランダムウォーク
 - 定常にも非定常にもなりうる: AR, ARMA

非定常過程の難しさ

- 性質を特徴付ける統計量が観測値から得られない
 - 平均や分散などの基本的な統計量が時間によって変動する
 - 1つの時系列から記述統計量の推測は一般にできない
- 擬似相関の問題
 - 2つの独立なランダムウォークは高い確率で“相関”を持つ
 - * 独立な時系列にも関わらず見掛けの相関が現れることがある
 - * <http://tylervigen.com/spurious-correlations>
 - 因果推論などの潜伏変数とは異なる問題

非定常過程の取り扱い

- 定常過程とみなせるように変換して分析を実行
 - 階差系列

ランダムウォークは階差をとればホワイトノイズ (定常過程) となる

$$X_t = X_{t-1} + \epsilon_t \quad \Rightarrow \quad Y_t = X_t - X_{t-1} = \epsilon_t$$

- 対数変換

対数変換と階差で微小な比率の変動を取り出すことができる

$$X_t = (1 + \epsilon_t)X_{t-1} \quad \Rightarrow \quad Y_t = \log(X_t) - \log(X_{t-1}) = \log(1 + \epsilon_t) \simeq \epsilon_t$$

- トレンド成分+季節成分+変動成分への分解

適当な仮説のもとに取り扱いやすい成分の和に分解する

自己共分散・自己相関

自己共分散・自己相関

- 確率過程 X_t が **定常過程** の場合
 - X_t と X_{t+h} の共分散は時点 t にらずラグ h のみで定まる
自己共分散 (定常過程の性質よりラグは $h \geq 0$ を考えればよい)

$$\text{Cov}(X_t, X_{t+h}) = \gamma(h)$$

- X_t と X_{t+h} の相関も t にらずラグ h のみで定まる

自己相関

$$\text{Cov}(X_t, X_{t+h})/\text{Var}(X_t) = \gamma(h)/\gamma(0)$$

- 異なる時点間での観測データの従属関係を要約する最も基本的な統計量

標本自己共分散・標本自己相関

- 観測データ $X_1, \dots, X_T$ からの推定
 - ラグ h の自己共分散の推定: 標本自己共分散

$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (X_t - \bar{X})(X_{t+h} - \bar{X})$$

$$\bar{X} = \frac{1}{T} \sum_{t=1}^T X_t \text{ は標本平均}$$

- ラグ h での自己相関の推定: 標本自己相関

$$\hat{\gamma}(h)/\hat{\gamma}(0) = \frac{\sum_{t=1}^{T-h} (X_t - \bar{X})(X_{t+h} - \bar{X})}{\sum_{t=1}^T (X_t - \bar{X})^2}$$

数値例

- 同じモデルに従うパス (系列) の自己相関を比較する
 - 自己回帰過程 (AR 過程)
 - 移動平均過程 (MA 過程)
 - 自己回帰移動平均過程 (ARMA 過程)

実習

次回の内容

- 第1回: 時系列の基本モデル
- 第2回: モデルの推定と予測




Figure 11: AR 過程の自己相関




Figure 12: MA 過程の自己相関




Figure 13: ARMA 過程の自己相関