

時系列解析

モデルの推定と予測

村田 昇

講義概要

- 第 1 回 : 時系列の基本モデル
- 第 2 回 : モデルの推定と予測

時系列解析の復習

時系列解析とは

- 時系列データ
 - 時間軸に沿って観測されたデータ
 - 観測の順序に意味がある
 - 異なる時点間での観測データの従属関係が重要
 - **独立性にもとづく解析は行えない**
 - * そのままでは大数の法則や中心極限定理は使えない
- 時系列解析の目的
 - 時系列データの特徴を効果的に記述すること
 - 時系列モデルの推定と評価

時系列モデルと定常性

- 確率過程
 - 時間を添え字として持つ確率変数列
$$X_t, t = 1, \dots, T$$
- 弱定常過程 : 以下の性質をもつ確率過程 X_t
 - X_t の平均は時点 t によらない
 - X_t と X_{t+h} の共分散は時点 t によらず時差 h のみで定まる
 - 特に X_t の分散は時点 t によらない ($h = 0$ の場合)
- 多くの場合, 弱定常性を考えれば十分なので単に **定常** ということが多い
- 定常でない確率過程は **非定常** であるという

ホワイトノイズ

- 定義
 - 平均 0, 分散 σ^2 である確率変数の確率分布 P からの独立かつ同分布な確率変数列
$$X_t = \epsilon_t, \quad \epsilon_t \stackrel{i.i.d.}{\sim} P$$
 - 記号 $WN(0, \sigma^2)$ で表記
 - **定常** な確率過程

トレンドのあるホワイトノイズ

- 定義

μ, α を定数として

$$X_t = \mu + \alpha t + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で定義される確率過程

- 非定常 な確率過程
- トレンド項 (平均値の変化) は現象に応じて一般化される

ランダムウォーク

- 定義

X_0 を定数もしくは確率変数として

$$X_t = X_{t-1} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で帰納的に定義される確率過程

- 分散が時間とともに増加・記憶のあるモデル
- 非定常 な確率過程

自己回帰過程

- 定義 (次数 p の AR モデル)

$a_1, \dots, a_p$ を定数とし, $X_1, \dots, X_p$ が初期値として与えられたとき,

$$X_t = a_1 X_{t-1} + \dots + a_p X_{t-p} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で帰納的に定義される確率過程

- ランダムウォークの一般化
- 無限長の記憶のある (忘却しながら記憶する) モデル
- 定常にも非定常にもなる

移動平均過程

- 定義 (次数 q の MA モデル)

$b_1, \dots, b_q$ を定数とし, $X_1, \dots, X_q$ が初期値として与えられたとき

$$X_t = b_1 \epsilon_{t-1} + \dots + b_q \epsilon_{t-q} + \epsilon_t, \quad \epsilon_t \sim \text{WN}(0, \sigma^2)$$

で定義される確率過程

- 有限長の記憶のあるモデル
- 定常 な確率過程

自己回帰移動平均過程

- 定義 (次数 (p, q) の ARMA モデル)

$a_1, \dots, a_p, b_1, \dots, b_q$ を定数とし, $X_1, \dots, X_{\max\{p, q\}}$ が初期値として与えられたとき

$$\begin{aligned} X_t &= a_1 X_{t-1} + \dots + a_p X_{t-p} \\ &\quad + b_1 \epsilon_{t-1} + \dots + b_q \epsilon_{t-q} + \epsilon_t, \\ \epsilon_t &\sim \text{WN}(0, \sigma^2) \end{aligned}$$

で帰納的に定まる確率過程

- AR・MA モデルの一般化・基本的な時系列モデル
- 定常にも非定常にもなる

自己共分散・自己相関

- 弱定常な確率過程: $X_t, t = 1, \dots, T$
 - X_t と X_{t+h} の共分散は時点 t によらずラグ h のみで定まる
- 自己共分散** (定常過程の性質よりラグは $h \geq 0$ を考えればよい)

$$\gamma(h) = \text{Cov}(X_t, X_{t+h})$$

- X_t と X_{t+h} の相関も t によらずラグ h のみで定まる

自己相関

$$\rho(h) = \gamma(h)/\gamma(0) = \text{Cov}(X_t, X_{t+h})/\text{Var}(X_t)$$

- 異なる時点間での観測データの従属関係を要約するための最も基本的な統計量

標本自己共分散・標本自己相関

- 観測データ $X_1, \dots, X_T$ からの推定
 - ラグ h の自己共分散の推定: 標本自己共分散

$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (X_t - \bar{X})(X_{t+h} - \bar{X})$$

$$\bar{X} = \frac{1}{T} \sum_{t=1}^T X_t \text{ は標本平均}$$

- ラグ h での自己相関の推定: 標本自己相関

$$\hat{\gamma}(h)/\hat{\gamma}(0) = \frac{\sum_{t=1}^{T-h} (X_t - \bar{X})(X_{t+h} - \bar{X})}{\sum_{t=1}^T (X_t - \bar{X})^2}$$




Figure 1: 同じモデルに従う AR 過程の例




Figure 2: AR 過程の自己相関




Figure 3: 同じモデルに従う MA 過程の例




Figure 4: MA 過程の自己相関




Figure 5: 同じモデルに従う ARMA 過程の例




Figure 6: ARMA 過程の自己相関

実習 (復習)

AR モデルの推定

自己共分散・自己相関

- 平均 0 の弱定常な確率過程: $X_t, t = 1, \dots, T$
 - X_t と X_{t+h} の共分散は時点 t にらずラグ h のみで定まる

自己共分散

$$\gamma(h) = \text{Cov}(X_t, X_{t+h}) = \mathbb{E}[X_t X_{t+h}]$$

- X_t と X_{t+h} の相関も t にらずラグ h のみで定まる

自己相関係数

$$\rho(h) = \text{Cov}(X_t, X_{t+h}) / \text{Var}(X_t) = \gamma(h) / \gamma(0)$$

自己共分散と AR モデル

- AR(p) モデル:

$$X_t = a_1 X_{t-1} + a_2 X_{t-2} + \dots + a_p X_{t-p} + \epsilon_t$$

- 係数と自己共分散の関係

$$\begin{aligned}\gamma(h) &= \mathbb{E}[X_t X_{t+h}] \\ &= \mathbb{E}[X_t (a_1 X_{t+h-1} + \dots + a_p X_{t+h-p} + \epsilon_{t+h})] \\ &= a_1 \mathbb{E}[X_t X_{t+h-1}] + \dots + a_p \mathbb{E}[X_t X_{t+h-p}] + \mathbb{E}[X_t \epsilon_{t+h}] \\ &= a_1 \gamma(h-1) + \dots + a_p \gamma(h-p)\end{aligned}$$

Yule-Walker 方程式

- $1 \leq h \leq p$ を考えると以下の関係が成り立つ

$$\begin{pmatrix} \gamma(1) \\ \gamma(2) \\ \vdots \\ \gamma(p) \end{pmatrix} = \begin{pmatrix} \gamma(0) & \gamma(-1) & \dots & \gamma(-p+1) \\ \gamma(1) & \gamma(0) & \dots & \gamma(-p+2) \\ \vdots & \vdots & \ddots & \vdots \\ \gamma(p-1) & \gamma(p-2) & \dots & \gamma(0) \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix}$$

- 行列は Toeplitz 行列と呼ばれる
- 行列が正則ならば AR の係数は一意に求まる

偏自己相関

- AR(p) モデル

$$X_t = a_1 X_{t-1} + a_2 X_{t-2} + \dots + a_p X_{t-p} + \epsilon_t$$

- ラグ p の **偏自己相関係数**

AR(p) モデルを仮定したときの a_p の推定値 (Yule-Walker 方程式の解)

- ラグ p の特別な **自己相関係数**

$a_1 = a_2 = \dots = a_{p-1} = 0$ のときの $\rho(p)$ (特殊なモデルにおける解釈)

$$\mathbb{E}[X_t X_{t+p}] = a_p \mathbb{E}[X_t X_t] \Rightarrow \gamma(p) = a_p \gamma(0) \Rightarrow \rho(p) = a_p$$




Figure 7: AR 過程の偏自己相関




Figure 8: MA 過程の偏自己相関




Figure 9: ARMA 過程の偏自己相関

モデルの推定に関する補足

- ARMA モデルの推定方法は主に以下の 3 つ
 - Yule-Walker 方程式 (AR 過程)
 - 最小二乗
 - * 予測誤差の平方和の最小化
 - * 回帰と同じだが、従属系列のため多重共線性に注意
 - 最尤推定
 - * WN の分布を仮定して同時尤度関数を設定
 - * 非線形最適化を行う
- 一般にモデルは近似なので、どの推定が良いかは問題による

非定常過程の変換

- 定常過程とみなせるように変換して分析
 - 階差の利用

$$X_t = X_{t-1} + \epsilon_t \quad \Rightarrow \quad Y_t = X_t - X_{t-1} = \epsilon_t$$

- * ランダムウォーク：階差をとるとホワイトノイズ (定常過程)
- * **ARIMA 過程**：階差をとると ARMA 過程になる確率過程
- 対数変換の利用

$$X_t = (1 + \epsilon_t)X_{t-1} \quad \Rightarrow \quad Y_t = \log(X_t) - \log(X_{t-1}) = \log(1 + \epsilon_t) \simeq \epsilon_t$$

- * 対数変換と階差で微小な比率の変動を抽出

実習

モデルによる予測

ARMA モデルによる予測

- 推定したモデルを用いて n 期先を予測
 - AR モデル：観測時点までの観測値を用いて回帰
 - MA モデル：観測時点までのホワイトノイズで回帰
 - ARMA モデル：上記の複合
- いずれも n が大きいと不確実性が増大
- 階差による変換は累積 (階差の逆変換) により推定
- 推定したノイズの不確実性にもとづき信頼区間を構成




Figure 10: ARIMA モデル (階差あり ARMA) による予測

分解モデルによる予測

- **トレンド + 季節 + ランダム** 成分への分解

$$X_t = T_t + S_t + R_t$$

あるいは

$$X_t = T_t \times S_t \times R_t \quad (\log X_t = \log T_t + \log S_t + \log R_t)$$

- **トレンド成分**: 時間の関数やランダムウォークなどを想定
- **季節成分**: 周期的な関数を想定
- **ランダム成分**: ARMA モデルなどを想定
- 分解の考え方
 - **ランダム成分**: 適切な幅の移動平均が 0
 - **季節成分**: 1 周期の平均が 0

Holt-Winter の方法

- 指数平滑化を用いた加法的分解モデルによる予測

$$l_t = \alpha(x_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1})$$

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma(x_t - l_t) + (1 - \gamma)s_{t-m}$$

$$\hat{x}_{t+h|t} = l_t + b_t \times h + s_{t-m+h}$$

- l_t, b_t は時刻 t における平均と傾きの推定値
- s_t は時刻 t における季節成分, m は季節性の周期
- 時刻 $t, t-1$ における推定を平滑化して推定量を構成
- ETS (error-trend-seasonal) モデルの一つ

- 基本的な考え方は乗法的分解に拡張可能
- 拡張したのが ETS モデルとも言える
- 状態空間モデルの特殊な場合とも考えられる




Figure 11: ETS モデル (exponential smoothing) による予測

解析事例

COVID-19 の感染者数の分析

- 厚生労働省の COVID-19 のデータ
 - 陽性者数 (新規・累積)
 - 重症者数 (推移・性別・年齢別)
 - 死者数 (推移・性別・年齢別・累積)
 - 入院治療等を要する者等推移
 - 集団感染等発生状況
- 以下の解析で用いるデータ
 - 日毎の全国・各都道府県の新規陽性者数 (感染者数) https://covid19.mhlw.go.jp/public/opendata/newly_confirmed_cases_daily.csv

感染者数の推移

第3波における感染者数の推移

基礎分析 (分析対象: 2020/9/15-11/30)

ARIMA モデルによる推定

- 推定された ARIMA モデル

```
Series: patients
Model: ARIMA(1,1,1)(2,0,0)[7]
Transformation: log(patients)
```

Coefficients:




Figure 12: 全国の感染者数




Figure 13: 第3波の感染者数




Figure 14: 時系列 (階差)




Figure 15: 時系列 (対数変換+階差)




Figure 16: 時系列 (対数変換+階差+7日階差)

```

          ar1      ma1      sar1      sar2
0.4493  -0.8309  0.3709  0.4232
s.e.   0.1635   0.0981  0.1212  0.1353

```

```

sigma^2 estimated as 0.03811:  log likelihood=15.04
AIC=-20.07  AICc=-19.21  BIC=-8.42

```




Figure 17: あてはめ値




Figure 18: 診断プロット

分析のまとめ

- 感染者数の推移は非定常なデータ
 - 構造が時不変と考えられる区間を捉えれば
 - 時系列の適切な変換 (指数的な増大のため対数変換)
 - 基本的な ARMA モデル (階差系列に ARMA モデルを適用)
- の組み合わせである程度の分析は可能




Figure 19: 予測値 (60 日分, 80%信頼区間)

実習