

Rによるデータ解析

R 言語の使い方

村田 昇

2020.09.25

R 言語の概要

R 言語とは

- 統計計算のための言語と環境の総称
- オープンソース・フリーソフトウェア
- 「パッケージ」を利用して容易に機能拡張が可能
 - パッケージの開発は非常に活発 (現在 10000 を越える)
 - 最新の技術や方法が簡単に導入できることも多い
- <https://www.r-project.org/> (プロジェクトのサイト)

RStudio とは

- RStudio 社が開発している統合開発環境 (IDE)
 - R によるデータ解析や統計計算・パッケージ開発を支援
 - OS に依存しない対話型操作環境を提供
- 本講義では RStudio を用いて説明を行う
- <https://www.rstudio.com/> (RStudio 社のサイト)

R の得意分野

- データの分類・集計・整理
 - 記述統計量 (基本・要約統計量) の計算
 - グラフによる視覚化
 - さまざまな統計分析 (多変量解析を含む)
- プログラムによる処理の自動化
- 擬似乱数による不確定性を含む現象の模擬 (確率的シミュレーション・モンテカルロ法)

多変量解析

多変量解析とは

- 複数の変量からなるデータを分析する手法の総称
 - 回帰分析: 複数の量を用いて注目する変数の値を説明する
 - 主成分分析: 全体を説明する少数の特徴量を構成する
 - 判別分析: 特徴量の違いでカテゴリ分けを行う

- クラスタ分析: 特徴量の違いに着目してクラスタを構成する
- 時系列解析: 時間とともに変化する現象を記述する

回帰分析の考え方

- ある変数を別の変数によって説明・予測するための関係式 (回帰式) を構成する
 - 単回帰: 一つの変数で目的変数を説明する
 - 重回帰: 複数の変数で目的変数を説明する
- 分析の事例:
 - 身長から体重を予測する式を作り, ある身長の人がある体重だったときに, それか普通かどうか判定する
 - 築年数・駅からの距離・広さ・間取りで家賃を説明する式を作り, 新規に家賃を設定する際に利用する

単回帰の例 (MASS::Animals)

表 1: 体重と脳の重さ

	body [kg]	brain [g]
Mountain beaver	1.350	8.1
Cow	465.000	423.0
Grey wolf	36.330	119.5
Goat	27.660	115.0
Guinea pig	1.040	5.5
Dipliodocus	11700.000	50.0
Asian elephant	2547.000	4603.0
Donkey	187.100	419.0
...		

重回帰の例 (wine.csv)

表 2: ワインの価格と生産環境

年号	価格 (対数)	冬の降雨	気温	秋の降雨	経過年
1952	-0.99868	600	17.1167	160	31
1953	-0.4544	690	16.7333	80	30
1954	NA	430	15.3833	180	29
1955	-0.80796	502	17.15	130	28
1956	NA	440	15.65	140	27
1957	-1.50926	420	16.1333	110	26
1958	-1.71655	582	16.4167	187	25
1959	-0.418	485	17.4833	187	24
...					

主成分分析の考え方

- 多数の変数か与えられたときに, 変数のもつ構造を効率的に記述できる少数個の特徴量を構成する
- 分析の事例:
 - 野球選手の打撃成績 (打率, 本塁打数, 打点など) から, 打者としての特徴を記述する指標を作成する
 - 複数銘柄からなる株価の時系列データから, 市場全体の変動を記述する総合指標を作成する




図 1: 体重と脳の重さの関係 (単回帰)




図 2: ワインの価格と生産環境の関係




図 3: 生産環境によるワイン価格の予測 (重回帰)

主成分分析の例 (jpamenity.csv)

表 3: 県別の生活環境 (一部)

	昼夜人口比	年少人口比	老年人口比	人口増減率
北海道	100.0	11.7	26.0	-0.47
青森県	100.0	12.1	27.0	-0.95
岩手県	99.7	12.4	27.9	-0.84
宮城県	100.2	13.0	22.9	-0.09
秋田県	99.9	11.1	30.7	-1.12
山形県	99.8	12.6	28.3	-0.78
福島県	99.6	12.9	26.1	-1.41
茨城県	97.2	13.2	23.8	-0.51

...

判別分析の考え方

- ある個体が複数のクラスのいずれかに属するとき、その個体の特徴量からどのクラスに属するか予測するモデルを構築する
- 分析の事例:
 - 花の種類を、その花の花弁の幅・長さおよび萼片 (かくへん) の幅・長さから判別する
 - 食道がんを患っている人とそうでない人を、年齢・飲酒量・喫煙度から判別する

判別分析の例 (MASS::biopsy)

表 4: 乳癌患者の生検検査

ID	V1	V2	V3	V4	V5	V6	V7	V8	V9	class
1000025	5	1	1	1	2	1	3	1	1	benign
1002945	5	4	4	5	7	10	3	2	1	benign
1015425	3	1	1	1	2	2	3	1	1	benign
1016277	6	8	8	1	3	4	3	7	1	benign
1017023	4	1	1	3	2	1	3	1	1	benign
1017122	8	10	10	8	7	10	9	7	1	malignant
1018099	1	1	1	1	2	10	3	1	1	benign
1018561	2	1	2	1	2	1	3	1	1	benign

...

クラスタ分析の考え方

- 特徴量の違いに着目して、妥当な個体のグループ (クラスタ) を構成する
 - 階層的な方法: 系統樹を作成する
 - 非階層的な方法: グループの代表値を推定する
- 分析の事例:
 - 映画に関するアンケート調査から潜在的なジャンル (グループ) を抽出する
 - 顧客の購買履歴から、嗜好の異なる顧客グループに分類し、グループごとの販売戦略を立てる

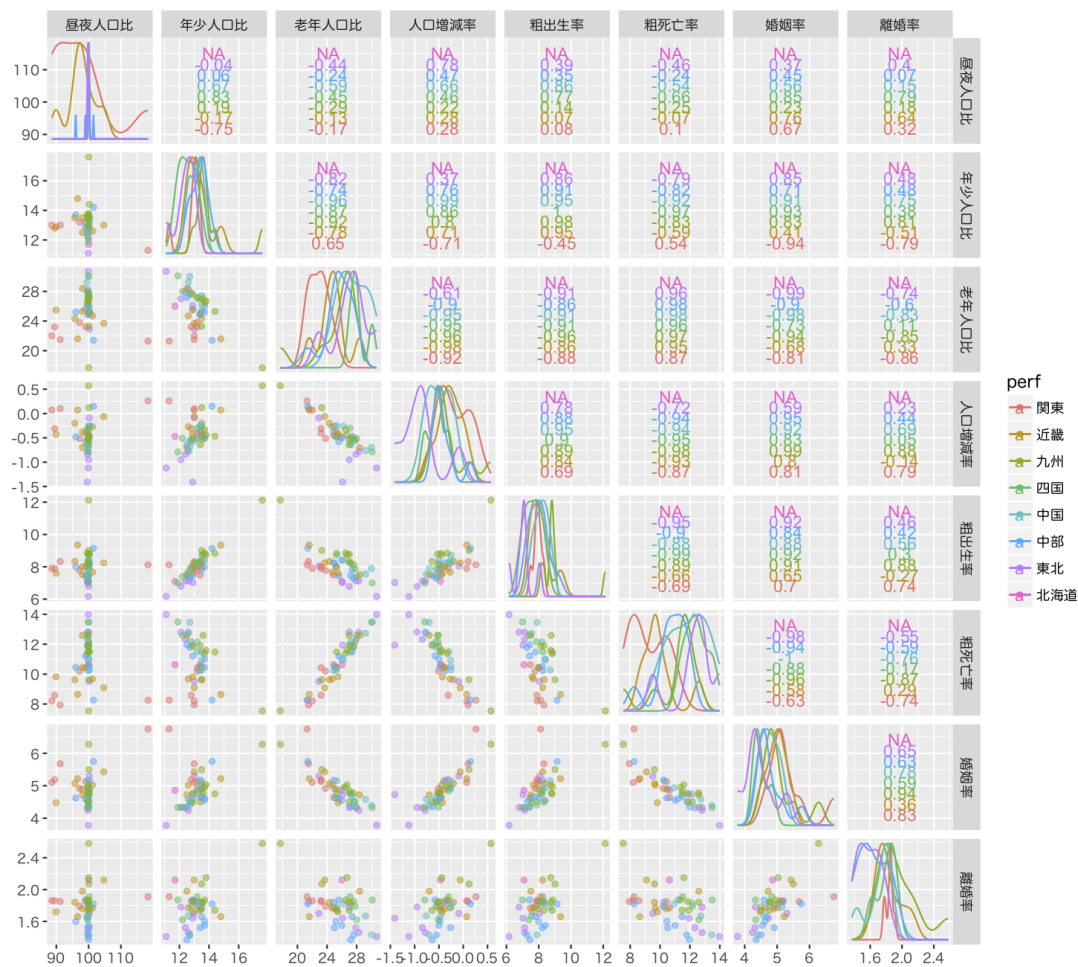


図 4: 県別の生活環境 (人口動態) の散布図

表 5: おむすびの具に関するアンケート

	梅	鮭	昆布	鰹	明太	鱈子	ツナ	他
北海道	13.86	27.94	5.58	5.26	9.26	15.06	11.61	11.39
青森	14.93	30.79	7.01	2.43	10.36	11.58	11.58	11.28
岩手	17.91	23.13	5.22	3.35	17.91	10.07	10.44	11.94
宮城	15.16	29.5	10	1.66	14.83	8.83	12.83	7.16
秋田	10.63	31.38	5.31	3.19	14.89	13.29	10.63	10.63
山形	16.58	20.27	8.29	1.38	18.89	10.13	12.9	11.52
福島	12.37	21.99	8.93	3.43	16.49	9.62	19.24	7.9
茨城	15.42	26.49	7.98	2.54	18.33	11.79	11.79	5.62
...								




図 5: 県別の生活環境 (教育・労働) の散布図




図 6: 県別の生活環境 (貯蓄・余暇) の散布図




図 9: 生研検査の主成分分析




図 10: 生研検査による乳癌患者の判別分析

Favorite Omusubi (2009)




図 11: おむすびの具に関するアンケート分析 (県別の集計)




図 12: アンケート結果にもとづく県のクラスタ分析

クラスタ分析の例 (omusubi.csv)

時系列解析の考え方

- 時間とともに変化する現象を記述するために、未来の値を過去の値で近似する式を構成する
 - 自己回帰 (AR モデル): 過去の影響の記述
 - 移動平均 (MA モデル): 記憶のある不確定性
- 分析の事例:
 - 市町村の過去の年齢別の人口変動から将来の人口比率を予測する
 - 食品・飲料の季節ごとの販売履歴から将来の需要量を予測する

時系列解析の例 (datasets::AirPassengers)

表 6: 航空機旅客量の変遷

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	...
1949	112	118	132	129	121	135	148	148	136	...
1950	115	126	141	135	125	149	170	170	158	...
1951	145	150	178	163	172	178	199	199	184	...
1952	171	180	193	181	183	218	230	242	209	...
1953	196	196	236	235	229	243	264	272	237	...
1954	204	188	235	227	234	264	302	293	259	...
1955	242	233	267	269	270	315	364	347	312	...
...										

RStudio の基礎

起動画面

- 以下 RStudio を用いて説明する
- 起動すると 4 つの枠 (pane) を持つウィンドウが立ち上がる
 - 左上: エディタ (開いていない場合もある)
 - 左下: コンソール
 - 右上: 作業環境内の変数・コマンド履歴
 - 右下: パッケージ・グラフィックス・ヘルプ
- ペインの配置や数は個別に設定することもできる

コンソール (左下)

- コマンドを入力するためのペイン
- 例えば、以下のような計算を行うことができる

```
## 一般的な数式を入力すれば計算機として使える
1 + 2 + 3 + 4 # 空白は無視される
sin(pi/3) / cos(pi/3) # tan(pi/3) になるはず
```

- コンソール上で終了を指示する以下のコマンドを入力すれば R を終了させることができる

```
## R の終了には q() または quit() を用いる
q()
```

- 終了できない場合は OS の機能で強制終了




図 13: 航空機旅客量の変遷




図 14: 階差時系列の自己相関分析




図 15: 航空機旅客量の予測 (SARIMA モデルによる)

作業ディレクトリ

- プログラムが実行されるディレクトリ (フォルダ)
- 作業ディレクトリにあるファイルの読み書きはパスを指定する必要がある
- 現在の作業ディレクトリはコンソールタブで確認
- **Session** メニューの **Set Working Directory** で指定
 - 読み込んだファイルの場所を選択
 - Files (右下ペイン) の場所を選択
 - ディレクトリを直接選択

エディタ (左上)

- コマンドを記述したファイルを扱うためのペイン
- コンソールに入力したコマンドは直ちに実行される
- 一連のコマンドをまとめたり、修正しながら実行するための機能
 - コマンドを実行順に記述したファイル **RScript** を作成
 - ファイルを保存
 - ファイルを実行

ヘルプ機能 (右下)

- 各関数の詳細 (機能, 引数名, 引数の既定値, 実行例など) を記述したヘルプが用意されている
- 右下ペイン **Help** タブ右上の検索窓で参照可能
- ヘルプ内の検索はその下の **Find in Topic** で可能

パッケージの操作 (右下)

- 機能を拡張するために多数のパッケージが用意されている
- RStudio でのインストール手順
 - 右下ペイン **Package** タブをクリック
 - 左上の **Install** をクリック
 - パッケージ名を入力し **Install** をクリック
- 利用可能なパッケージの情報は右下ペイン **Package** タブで確認できる

終了時の注意

- 終了時に以下のメッセージが表示される場合がある

```
> q()  
Save workspace image? [y/n/c]:
```

- 作業で使った変数などをセーブするか尋ねている
 - y を入力: セーブする (yes の略)
 - n を入力: セーブしない (no の略)
 - c を入力: R の終了をキャンセルする (cancel の略)
- セーブした場合次回起動時に読み込まれる

基本的な使い方

式の入力

- 四則演算や数学関数は直感的な文法で計算可能
 - + (加算), - (減算), * (乗算), / (除算), ^ または ** (べき乗)
 - sin, cos, tan (三角関数), exp (指数関数), log (対数関数)
- コンソール上での計算例

```
## コンソールに以下のコマンドを入力してみる
123 * 456 - 789
(2^2^5 + 1) / 641
sin(pi/3)^2 + cos(pi/3)^2
```

```
[1] 55299
[1] 6700417
[1] 1
```

エディタからの実行

- 新規ファイルの作成 (以下のいずれか)
 - 左上の + から **R Script** を選択
 - **File** から **New File** を選択, 更に **R Script** を選択
- エディタ上でコマンドを記述
- 実行範囲の選択
 - 一行のみ: カーソルをその行に移動
 - 複数行: クリックしながら移動して選択する
- 選択範囲の実行 (以下のいずれか)
 - 左上の **Run** をクリック
 - **Code** から **Selected Line(s)** を選択 (Ctrl/Command+Enter)

ファイルの保存

- ファイルの保存 (以下のいずれか)
 - 左上のディスクのマークをクリック
 - **File** から **Save** を選択 (Ctrl/Command+S)
- ファイル作成に関する注意
 - 保存する時にファイル名の入力が求められる
 - 拡張子は通常 **.R** または **.r** を利用する
 - # 以降の字列は実行されない (**コメントを残す際に有用**)

関数の実行

- 関数の取り扱いは一般的な計算機言語とほぼ同様
- 関数は引数とその値を指定して実行
- 正弦関数の計算

```
sin(x = pi/2)
## 上と同値. 関数の定義どおりの順序であれば引数の名前は省略可能
sin(pi/2)
```

- 対数関数の計算

```
## xやbに具体的な数値を代入して実行してなさい
log(x, b) # 底をbとする対数
log(x=x, base=b) # 上と同値
log(base=b, x=x) # 上と同値
log(b,x) # = log(x=b, base=x)
log(x) # base を省略すると自然対数 =log(x, base=exp(1))
```

オブジェクト

- Rで扱うことのできる数値
 - 実数および複素数 (指数表記にも対応)
 - 無限大や不定な数など特殊なものにも対応
- 変数, 関数, 計算結果などを **オブジェクト** と呼ぶ
- 文字列を変数名としてオブジェクトを保持することができる
- 保持しているオブジェクトの情報は右上ペインの **Environment** タブで確認できる

オブジェクトの代入

- オブジェクトの内容 (情報) を別のオブジェクトに代入することができる
- 計算結果や良く使う文字列の保存に利用できる
- 代入操作

```
## 数値を変数 foo に代入する
(foo <- 3)
## 変数 foo を用いて計算し, 結果を bar に代入する
bar <- sin(2/3*pi) + cos(foo * pi/4)
## 変数 bar の内容を表示する
print(bar)
```

```
[1] 3
[1] 0.1589186
```

データの読み込み

- ファイルにまとめられたデータを読み込むことができる
- 対応する形式は csv・excel など
- 右下ペインの **Files** を利用する
 - ファイルが保存されているディレクトリに移動
 - ファイルをクリック
 - View File** (見るだけ) か **Import Dataset** (読み込み) を選択